Projet ALG 2026 : FM-index coloré

Comparaison d'un FM-index généralisé et de N FM-index avec filtres de Bloom

Matys Dulong et Corentin Perrot – M2 Bioinformatique Rennes

Octobre 2026

1 Choix d'implémentation

Le code est écrit en Python 3.12 ; son utilisation est décrite dans le README. Les génomes sont lus avec pyfastx : chaque séquence d'un fichier FASTA est un contig, gardé séparé des autres.

FM-index (`fm_index.py`). Le suffix array est calculé avec pydivsufsort puis jeté : seuls la BWT (une chaîne), la table Count (`first_occurrence`, une entrée par lettre de `$ACGT`) et la table Rank (`occ`) sont conservés. `occ` est complète : pour chaque lettre, une liste de $n + 1$ entiers donnant le nombre d'occurrences de la lettre dans `bwt[0:i]`. Le rang est donc lu en $O(1)$ et la recherche arrière d'une requête q coûte $O(|q|)$, au prix d'une table de $5(n + 1)$ entiers.

Approche 1 : FM-index généralisé (`generalized_index.py`). Le texte indexé est la concaténation de tous les contigs de tous les génomes, chacun suivi de `$`. Comme les requêtes ne contiennent pas de `$`, une requête ne peut pas être trouvée à cheval sur deux contigs ou deux génomes. Le color array est rempli à partir du suffix array : la case i reçoit le numéro du génome (ordre du FOF) où commence le suffixe de la ligne i. Une requête est cherchée une seule fois : on lit les couleurs de l'intervalle `[top, bottom]` renvoyé par la recherche arrière.

Approche 2 : N FM-index et N filtres de Bloom (`bf_index.py`). Pour chaque génome, on construit un FM-index de ses contigs séparés par `$` et un filtre de Bloom de m bits (bitarray) avec h fonctions de hachage (mmh3 avec les graines 0 à $h - 1$), rempli avec tous les k-mers de chaque contig (aucun k-mer à cheval sur deux contigs). Pour une requête, on teste son premier k-mer dans chaque filtre et on n'interroge que les FM-index dont le filtre répond oui. Un filtre de Bloom n'a pas de faux négatif, et ses faux positifs sont corrigés par le FM-index : le résultat est donc exact. Une requête plus courte que k n'a pas de premier k-mer : tous les FM-index sont alors interrogés.

Programmes et validation. `index_colored_fm_index.py` et `query.py` suivent l'interface du sujet ; les paramètres des filtres sont ajoutés en options (`-k`, `--bloom_size`, `--num_hashes`, défauts 21, 2^{24} et 3). L'index est sérialisé avec pickle et les temps mesurés avec `time.perf_counter` ; `TIME_BUILD` ne compte pas la lecture des FASTA. 23 tests pytest valident chaque structure. En particulier, `test_consistency.py` vérifie que les deux approches et une recherche naïve (`q in contig`) donnent le même résultat sur 350 requêtes et des génomes aléatoires qui se recouvrent, puis sur 200 requêtes réelles E. coli, et que les deux programmes produisent des fichiers de résultats identiques.

Nous n'avons pas implémenté d'optimisation (couleurs sur $\lceil \log_2 N \rceil$ bits, échantillonnage de `occ`) : la section 4 explique, à partir de nos mesures, laquelle serait la plus utile.

2 Protocole expérimental

Données. Les 4 collections fournies sur Moodle, de 49 génomes chacune : des génomes d'E. coli tronqués à leurs 10 kb ou 100 kb (premiers contigs, 1 à 33 contigs par génome, 94 à 98 kb pour la version 100 kb) et des génomes aléatoires de 10 kb ou 100 kb (un contig). Pour chaque collection, 1960 requêtes de 100 pb et 196 requêtes de 1000 pb. Les requêtes aléatoires sont toutes présentes dans exactement un génome ; celles d'E. coli sont présentes en moyenne dans 2,4 génomes (100 pb, au plus 16) et 1,0 à 1,2 génome (1000 pb), car les souches partagent des séquences, et quelques-unes (jusqu'à 5 %) ne sont présentes dans aucun génome.

Expérience 1 (comparaison des approches). `benchmark.py` lance les deux programmes, comme un utilisateur, sur les $N = 5, 10, 20, 35, 49$ premiers génomes de chaque collection, avec les paramètres par défaut ($k = 21$, $h = 3$, $m = 2^{24}$). On relève les quatre temps affichés par les programmes, la taille du fichier sérialisé, et la taille de l'index relu en mémoire vive (`pympler.asizeof`, une seule fois par configuration). Les temps sont la moyenne de 3 répétitions.

Expérience 2 (paramètres des filtres). Sur les 49 génomes E. coli de 100 kb et les 1960 requêtes de 100 pb, on fait varier un paramètre à la fois autour de $k = 21$, $m = 2^{20}$, $h = 3$. Le taux de faux positifs est, parmi les couples (requête, génome) où le premier k-mer est absent du génome (vérifié sur les contigs), la part où le filtre répond oui. On mesure aussi la part de FM-index interrogés « pour rien » (le filtre répond oui mais la requête est absente du génome, faux positifs compris).

Machine. Linux, 8 cœurs, 7,6 Go de RAM, Python 3.12.16. La machine était chargée (swap utilisé) : d'une passe complète à l'autre, les temps absolus ont varié jusqu'à un facteur 2,7 (temps de requête), mais l'ordre entre les deux approches est resté le même. Nous interprétons donc surtout des rapports entre approches. Toutes les commandes de reproduction sont dans le README.

3 Résultats

Résultat 1 : la construction et la mémoire

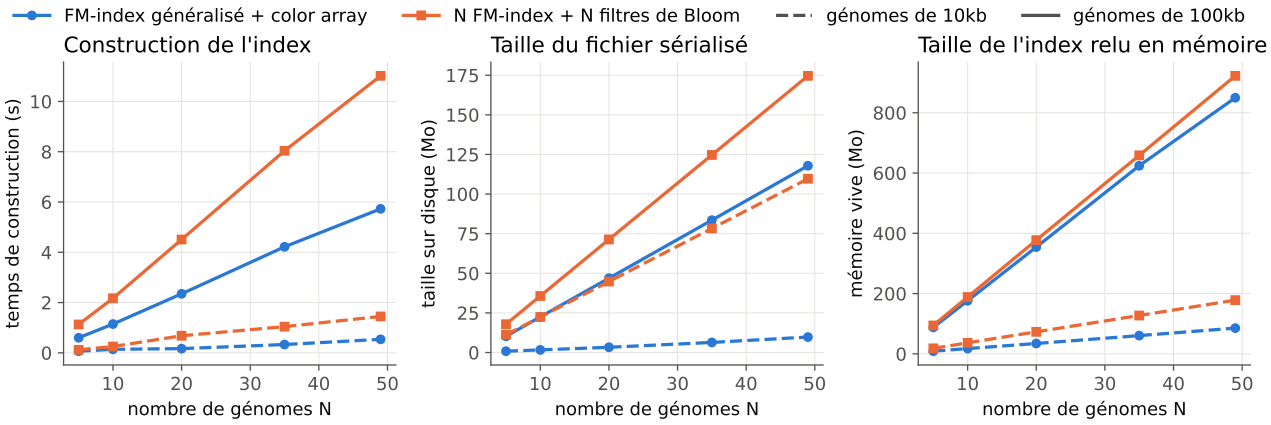


Figure 1 – Temps de construction, taille sur disque et taille en mémoire vive des deux index selon le nombre de génomes N. Collections E. coli de 10 kb (tirets) et 100 kb (traits pleins) ; $k = 21$, $h = 3$, $m = 2^{24}$ pour `bf`. Temps : moyenne de 3 répétitions.

Interprétation. Les trois mesures croissent linéairement avec la taille totale des génomes. `bf` se construit environ 2 fois moins vite (11,0 s contre 5,7 s pour 49 génomes de 100 kb) : en plus des N FM-index, il faut hacher h fois chacun des 4,8 millions de k-mers en Python (l'expérience 2 montre

que chaque fonction de hachage en plus coûte environ 0,9 s). Sur disque, `bf` est plus gros avec le m par défaut : chaque filtre fait 2 Mo quelle que soit la taille du génome, ce qui représente 103 Mo des 110 Mo de l'index pour des génomes de 10 kb.

Surtout, **la taille sur disque sous-estime fortement la mémoire vive** : 118 Mo sur disque contre 850 Mo en RAM pour `generalized` (facteur 7 à 11 selon les configurations), 175 Mo contre 923 Mo pour `bf`. En mesurant chaque attribut séparément, la table `occ` représente à elle seule 807 Mo (95 %), contre 38 Mo pour le color array et 5 Mo pour la BWT. En effet, pickle écrit chaque entier sur 2 à 5 octets, alors qu'une fois relu, chaque entier de `occ` est un objet Python d'environ 28 octets, plus 8 octets de pointeur dans la liste ($5 \times 4{,}8 \cdot 10^6 \times 36 \approx 860$ Mo). Le facteur est plus faible pour `bf` (5,3 à 100 kb, 1,6 à 10 kb) car ses filtres (bitarray) ont la même taille sur disque et en mémoire. En RAM, les deux approches sont donc proches (9 % d'écart à 49 génomes de 100 kb), car elles stockent le même nombre total d'entrées dans `occ`. Le temps de désérialisation suit le nombre d'objets Python à recréer plutôt que la taille du fichier (annexe A, figure A1).

Résultat 2 : les requêtes, `generalized` fait moins de travail

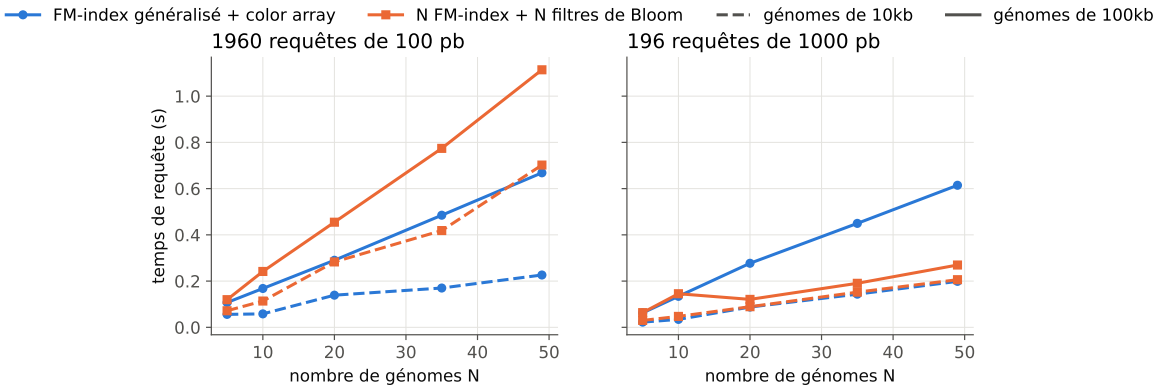


Figure 2 – Temps total des requêtes selon le nombre de génomes N, pour des requêtes de 100 pb (gauche) et de 1000 pb (droite). Collections E. coli ; même légende que la figure 1. Le temps est mesuré par `query.py`, juste après la relecture de l'index.

Interprétation. Pour 1960 requêtes de 100 pb, `generalized` est plus rapide (0,67 s contre 1,11 s pour 49 génomes de 100 kb). C'est ce qu'on attend : `generalized` fait une seule recherche arrière par requête, alors que `bf` teste d'abord le premier k-mer dans les 49 filtres (4 µs par filtre, soit environ 0,4 s pour les 1960 requêtes), puis fait une recherche dans chaque génome dont le filtre répond oui. Comme les souches d'E. coli partagent beaucoup de k-mers, c'est le cas de 4 génomes en moyenne (jusqu'à 16), et `bf` fait au total 2,9 fois plus d'étapes de recherche arrière (291 contre 100 par requête), pour un coût par étape identique dans les deux index (0,6 à 0,8 µs).

Pour 196 requêtes de 1000 pb, `bf` est au contraire mesuré plus rapide par `query.py` (0,27 s contre 0,61 s). Ce résultat ne s'explique pas par les structures : `bf` fait là encore plus de travail (4 recherches et 1533 étapes par requête en moyenne, contre 993 étapes pour `generalized`). Mesurées dans un script séparé, sur les mêmes index, ces requêtes prennent d'ailleurs 0,12 à 0,13 s avec `generalized` contre 0,19 à 0,25 s avec `bf`. L'écart mesuré par `query.py` dépend donc des conditions d'exécution juste après la relecture d'un gros index, et nous ne le retenons pas comme un avantage de `bf`.

Résultat 3 : la taille des filtres suit la théorie, et $m = 2^{20}$ suffit

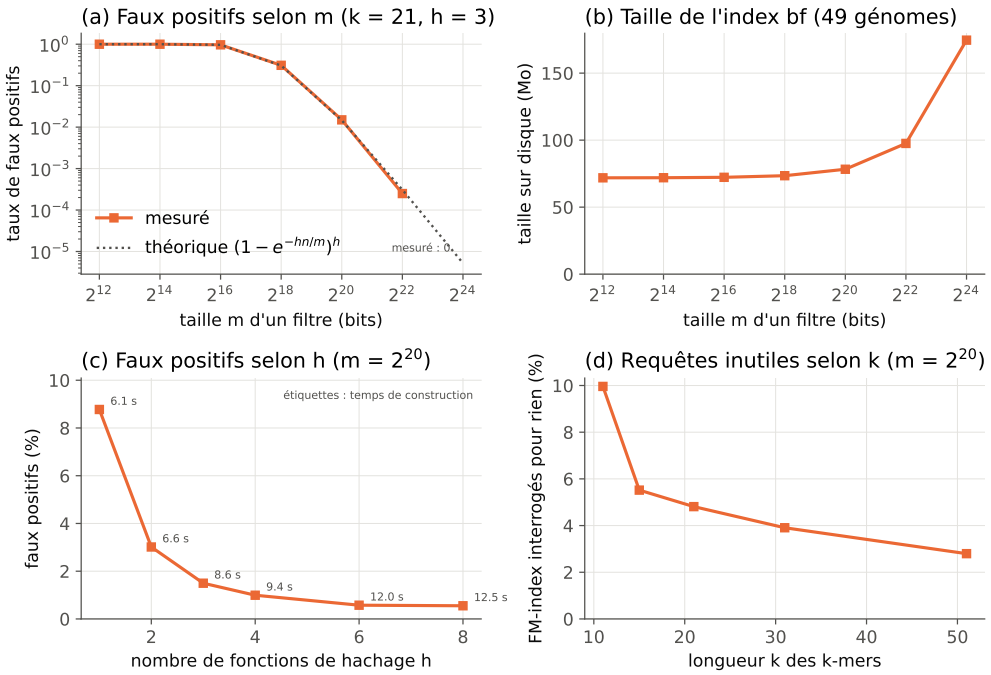


Figure 3 – Effet des paramètres des filtres de Bloom sur l'index `bf`. 49 génomes E. coli de 100 kb, 1960 requêtes de 100 pb ; un seul paramètre varie, autour de $k = 21$, $m = 2^{20}$, $h = 3$. (a) Taux de faux positifs selon la taille m d'un filtre (échelles log), comparé à la formule théorique avec $n \approx 98\,000$ k-mers par génome. (b) Taille du fichier sérialisé selon m. (c) Taux de faux positifs selon le nombre h de fonctions de hachage ; les étiquettes donnent le temps de construction. (d) Part des couples (requête, génome) où un FM-index est interrogé pour rien, selon k.

Interprétation (a, b). Le taux de faux positifs mesuré suit la formule $(1 - e^{-hn/m})^h$: 31 % contre 30,6 % attendus pour $m = 2^{18}$, 1,50 % contre 1,46 % pour $m = 2^{20}$. Les h fonctions de notre filtre (mmh3 avec des graines différentes) se comportent donc comme des fonctions de hachage indépendantes. Jusqu'à 2^{16} bits, les filtres sont saturés (presque tous les bits à 1) : 47 à 49 FM-index sont interrogés par requête au lieu de 4 à 5, et les requêtes sont 2 à 3 fois plus lentes (1,6 à 2,0 s contre 0,66 à 0,70 s à partir de 2^{20}). Au-dessus de 2^{20}, les faux positifs ne coûtent presque plus rien, mais la taille explose : les 49 FM-index seuls font 72 Mo, et les filtres ajoutent $49 \times m/8$ octets, soit 6 Mo pour 2^{20} mais 103 Mo pour 2^{24}. **$m = 2^{20}$ (environ 10 bits par k-mer) est un bon choix pour des génomes de 100 kb** : 1,5 % de faux positifs et un index de 78 Mo, plus petit que celui de `generalized` (118 Mo). Cette différence vient surtout de pickle : dans un génome de 100 kb, les valeurs de `occ` restent sous 65 536 et sont écrites sur 3 octets au plus, alors qu'elles dépassent cette valeur dans l'index généralisé et prennent alors 5 octets. Notre valeur par défaut (2^{24}) est donc surdimensionnée pour ces données.

Interprétation (c, d). Augmenter h fait baisser les faux positifs (8,8 % pour $h = 1$, 1,5 % pour $h = 3$, 0,55 % pour $h = 8$), mais chaque k-mer est haché h fois et la construction passe de 6,1 à 12,5 s. La théorie donne un optimum $h = (m/n) \ln 2 \approx 7$ pour $m = 2^{20}$, mais le gain au-delà de $h = 3$ ou 4 est faible par rapport au coût. k change peu le taux de faux positifs (1,2 à 1,5 %, car le nombre de k-mers par génome varie peu), mais un premier k-mer plus long est plus spécifique : la part de FM-index interrogés pour rien passe de 10 % ($k = 11$) à 2,8 % ($k = 51$). k ne doit cependant pas dépasser la longueur des requêtes : pour une requête plus courte que k, le filtre n'est pas utilisé.

Résultat 4 : le type de données change peu les performances

Table 1 – Récapitulatif pour N = 49 génomes, par collection. Temps en secondes (moyenne de 3 répétitions), tailles en Mo. Désérialisation : moyenne des deux fichiers de requêtes. Paramètres par défaut pour `bf` ($m = 2^{24}$).

			indexation		taille (Mo)			requêtes	
données	génomes	méthode	constr.	sérial.	disque	RAM	désérial.	100 pb	1000 pb
coli	10 kb	generalized	0,54	0,12	9,8	85	0,12	0,23	0,20
coli	10 kb	bf	1,45	0,39	109,7	178	0,33	0,70	0,21
coli	100 kb	generalized	5,73	1,01	117,9	850	1,17	0,67	0,61
coli	100 kb	bf	11,02	1,44	174,6	923	1,65	1,11	0,27
random	10 kb	generalized	0,56	0,11	10,2	88	0,12	0,21	0,20
random	10 kb	bf	1,57	0,39	109,9	182	0,37	0,38	0,17
random	100 kb	generalized	5,97	1,05	120,5	892	1,18	0,62	0,64
random	100 kb	bf	11,78	1,14	176,1	936	1,75	0,82	0,19

Interprétation. À taille égale, les génomes E. coli et aléatoires donnent les mêmes temps de construction et les mêmes tailles : un FM-index contient autant d'entrées quel que soit le contenu du texte. Les conclusions des résultats 1 et 2 valent donc pour les deux types de données. La seule différence concerne les requêtes de `bf` : elles ont tendance à être plus lentes sur E. coli (1,11 s contre 0,82 s pour 100 pb à 100 kb). Les souches partagent beaucoup de k-mers : le premier k-mer d'une requête se trouve souvent dans plusieurs génomes (4 en moyenne), si bien que plus de FM-index sont interrogés, alors que chaque requête aléatoire n'est présente que dans un seul génome. Des génomes aléatoires, qui ne partagent presque aucun k-mer, sont donc le cas le plus favorable aux filtres de Bloom. Pour 100 pb, les temps de requête varient toutefois d'une passe à l'autre, et cet écart doit être pris avec prudence.

4 Conclusion et recommandations

Les deux approches donnent les mêmes résultats ; le choix dépend des contraintes de l'utilisateur :

— **temps de construction** ou **temps de requête** : `generalized`, environ 2 fois plus rapide à construire et qui ne fait qu'une recherche arrière par requête, contre 4 en moyenne pour `bf` sur des génomes proches comme ceux d'E. coli ;
— **espace disque** : `bf` avec des filtres bien dimensionnés (78 Mo contre 118 Mo) ; en mémoire vive, les deux sont proches ;
— **collection qui grandit** : `bf`, où un génome s'ajoute sans reconstruire les autres (méthode `add_genome`), alors que `generalized` doit tout reconstruire.

Pour `bf`, nous conseillons $m \approx 10$ bits par k-mer du plus gros génome (2^{20} pour 100 kb, 2^{17} pour 10 kb), $h = 3$ et k entre 21 et 31, sans dépasser la longueur de la plus courte requête.

Limites et optimisations possibles. Nos temps ont été mesurés sur une machine chargée et varient d'une passe à l'autre ; seules les comparaisons entre approches sont fiables. Notre principale limite est la mémoire vive, jusqu'à 11 fois plus grande que le fichier pour `generalized`, à cause des listes d'entiers Python de `occ`. D'après nos mesures, l'optimisation la plus utile ne serait pas de coder les couleurs sur $\lceil \log_2 49 \rceil = 6$ bits (le color array représente moins de 5 % de la RAM), mais de réduire `occ` : ne stocker qu'une valeur sur 32 et compter le reste dans la BWT, ou stocker les compteurs dans des tableaux d'entiers compacts (module `array`, 4 octets par valeur, soit environ 100 Mo au lieu de 807 Mo). Le color array deviendrait alors une part plus importante de l'index, et le codage des couleurs sur $\lceil \log_2 N \rceil$ bits un gain intéressant.

A Annexe : temps de désérialisation

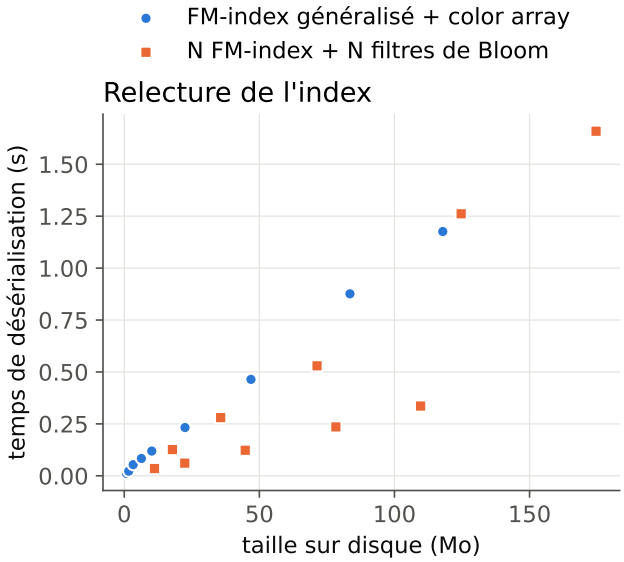


Figure A1 – Temps de désérialisation selon la taille du fichier sérialisé. Toutes les configurations E. coli de l'expérience 1 (10 et 100 kb, N de 5 à 49). Cité dans le résultat 1.

À taille de fichier égale, l'index `bf` construit sur des génomes de 10 kb (les carrés orange les plus bas) se relit 3 à 4 fois plus vite que `generalized` (par exemple 110 Mo en 0,33 s contre 118 Mo en 1,17 s). Ces fichiers sont surtout faits de filtres (des tableaux de bits relus d'un bloc), alors que relire `occ` oblige à recréer un objet Python par entier. Le temps de relecture dépend donc du nombre d'objets, comme la mémoire vive (résultat 1), plus que du nombre d'octets.